

Ανίχνευση Δικτυακών Εισβολών με Μηχανική Μάθηση

Ανάλυση του Συνόλου Δεδομένων CIC-IDS-2017

Εξόρυξη Δεδομένων & Μηχανική Μάθηση

Βασίλειος Μπίτζας 1083796 up1083796@ac.upatras.gr

Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών & Πληροφορικής
Πανεπιστήμιο Πατρών

23 Απριλίου 2026

Περιεχόμενα

1	Εισαγωγή	7
1.1	Πλαίσιο και Κίνητρο	7
1.2	Στόχοι Εργασίας	7
1.3	Περιγραφή Δεδομένων	7
1.3.1	CIC-IDS-2017 Dataset	7
1.3.2	Συνοπτικά Μεγέθη	8
1.4	Διάρθρωση της Αναφοράς	8
2	Θεωρητικό Υπόβαθρο	10
2.1	Προεπεξεργασία Δεδομένων	10
2.1.1	Missing Values και Infinities	10
2.1.2	Εξαιρετικά Διπλότυπα	10
2.2	Κλάσεις σε Ανισορροπία	10
2.3	Pearson Correlation	11
2.3.1	Τυφλά Σημεία	11
2.4	Multicollinearity	11
2.5	log1p Transform και Skewness	12
2.6	Stratified Sampling για Οπτικοποίηση	12
2.7	Αξιολόγηση Ταξινομητών (Q2)	12
2.7.1	Confusion Matrix	12
2.7.2	Precision, Recall, F1	12
2.7.3	Grid Search Cross-Validation	13
2.8	Συσταδοποίηση (Q3)	13
2.8.1	K-Means	13
2.8.2	DBSCAN	13
2.8.3	Hierarchical Clustering	13
2.8.4	External Validation με ARI	13
3	Ερώτημα 1: Exploratory Data Analysis	14
3.1	Επισκόπηση του Pipeline	14
3.2	Φόρτωση και Επισκόπηση	14
3.2.1	Ενοποίηση των 8 CSV	14
3.2.2	Καθαρισμός Ετικετών	14
3.3	Καθαρισμός Δεδομένων	15
3.3.1	Infinities και Missing Values	15
3.3.2	Duplicates	15
3.4	Κατανομή Κλάσεων	15
3.5	Περιγραφικά Στατιστικά	17
3.6	Οπτικοποιήσεις	17
3.6.1	Ιστογράμματα Top Features	17
3.6.2	Boxplots	17
3.6.3	Correlation Heatmap	18
3.6.4	Top Correlated Pairs	19

3.6.5	Correlation με το Label	20
3.7	Feature Selection	20
3.7.1	Κριτήρια Αφαίρεσης	20
3.7.2	Αποτελέσματα	21
3.7.3	Τελική Λίστα Features	21
3.8	Αποθήκευση του Clean Snapshot	21
3.9	Σύνοψη Q1	22
4	Ερώτημα 2: Ταξινόμηση	23
4.1	Μεθοδολογία	23
4.1.1	Stratified Subsampling με Per-Class Cap	23
4.1.2	Encoding, Scaling και Imbalance Handling	23
4.1.3	Πρωτόκολλο Splits	24
4.1.4	Scoring Metric για την Επιλογή Hyperparameters	24
4.2	Logistic Regression	24
4.3	Decision Tree	25
4.4	Random Forest	27
4.5	Συγκριτική Ανάλυση	29
4.5.1	Απαντήσεις στις Τέσσερις Ερωτήσεις της Εκφώνησης	30
4.6	Σύνοψη Q2	32
5	Ερώτημα 3: Συσταδοποίηση	33
5.1	Preprocessing και PCA	33
5.2	K-Means	34
5.3	Hierarchical (Agglomerative)	36
5.4	DBSCAN	38
5.5	Συγκριτική Ανάλυση	40
5.5.1	Απαντήσεις στις Ερωτήσεις της Εκφώνησης	40
5.6	Σύνοψη Q3	41
6	Συμπεράσματα	42
6.1	Σύνοψη Όλου του Αγωγού	42
6.2	Συμπεράσματα ανά Ερώτημα	42
6.2.1	Q1 - Δομή και Καθαρισμός των Δεδομένων	42
6.2.2	Q2 - Supervised Classification	42
6.2.3	Q3 - Unsupervised Clustering	43
6.3	Συνολικά Διδάγματα και Best Practices	43
6.4	Πιθανές Επεκτάσεις	43
Α'	Οδηγίες Εγκατάστασης και Εκτέλεσης	44
Α'.1	Απαιτήσεις	44
Α'.2	Εγκατάσταση	44
Α'.3	Εκτέλεση του Q1	44
Α'.4	Εκτέλεση των Q2 και Q3	45
Α'.5	Αναπαραγωγικότητα	45

Κατάλογος Σχημάτων

3.1	Κατανομή κλάσεων στο καθαρισμένο CIC-IDS-2017. Το αριστερό σχήμα χρησιμοποιεί λογαριθμικό άξονα ώστε να φαίνονται και οι σπάνιες κλάσεις (Heartbleed, Sql Injection, Infiltration).	16
3.2	Ιστογράμματα με KDE για τις 20 στήλες μεγαλύτερης διασποράς (log1p scale). Οι περισσότερες κατανομές είναι έντονα λοξές και heavy-tailed.	17
3.3	Boxplots (log1p scale) για τις 20 στήλες μεγαλύτερης διασποράς. Τα outliers πάνω από τα whiskers είναι διαγνωστικά για επιθέσεις DoS/DDoS και δεν αφαιρούνται.	18
3.4	Pearson correlation heatmap των 77 αριθμητικών features. Τα μεγάλα κόκκινα clusters αντιστοιχούν σε αλγοριθμικές ταυτότητες του CICFlowMeter (π.χ. Subflow Fwd Bytes $\approx$ Total Length of Fwd Packets).	19
4.1	Logistic Regression (Σενάριο B) - heatmap των συντελεστών για τα top-15 features (κατά μέσο $ \text{coef} $ σε όλες τις κλάσεις). Έντονο κόκκινο = το feature οδηγεί strongly προς αυτή την κλάση· έντονο μπλε = αντενδείκνυται. Παράδειγμα: η PortScan έχει σαφώς θετικούς συντελεστές στα Bwd Packet Length Min και Bwd Packets/s (μικρά backward packets σε υψηλό rate - υπογραφή scanning).	25
4.2	Decision Tree (Σενάριο B, actual best) - top 3 levels. Το πραγματικό δέντρο μπορεί να φτάνει σε πολύ μεγαλύτερο βάθος, αλλά τα πρώτα splits χωρίζουν τις περισσότερες κλάσεις.	26
4.3	Standalone shallow Decision Tree (max_depth = 3, entropy) εκπαιδευμένο ξεχωριστά για clean visualization. Όχι το best model - απλώς δείχνει πώς θα μοιάζει ένα ολόκληρο δέντρο 3 επιπέδων.	27
4.4	Top-20 feature importances του Random Forest (Σενάριο B).	28
4.5	Random Forest (Σενάριο B) - top 3 levels του πρώτου voter του δάσους (από τα 100 δέντρα συνολικά). Τα splits εδώ διαφέρουν από αυτά του standalone DT - σημείο της feature randomness που επιβάλλει το RF.	29
4.6	F1-weighted έναντι F1-macro και για τις 6 παραλλαγές. Η διαφορά $F1_w - F1_m$ είναι η «υπογραφή του imbalance»: πόσο «χρωστά» το μοντέλο την απόδοσή του στις μεγάλες κλάσεις.	30
4.7	Random Forest (Σενάριο B) - row-normalized confusion matrix. Οι διαγώνιοι κοντά στο 1 δείχνουν per-class recall· οι off-diagonal entries δείχνουν confusion patterns.	31
4.8	Logistic Regression (Σενάριο B) - row-normalized confusion matrix. Σημαντικά χειρότερη ποιότητα στις Web-Attack και Bot κλάσεις σε σχέση με το RF.	32
5.1	PCA explained variance: per-component (μπλε bars) και cumulative (κόκκινη γραμμή). Με 17 components καλύπτουμε $\sim 87\%$ της variance· επιλέγουμε αυτό ως input για όλους τους αλγορίθμους clustering. Παρατηρήστε ότι ο πρώτος component συλλαμβάνει μόνο $\sim 17\%$: δεν υπάρχει ένα κυρίαρχο axis. Η information είναι κατανομημένη σε πολλά components.	34
5.2	K-Means - inertia (μπλε) και silhouette (κόκκινο) ανά k . Το silhouette κορυφώνεται στο $k = 15$ - ο ίδιος αριθμός με τα γνωστά labels.	35

5.3	K-Means $k = 15$ - PCA 2-D scatter. Αριστερά: colored by cluster. Δεξιά: colored by true Label. Παρατηρήστε ότι μερικές classes (DDoS, PortScan) είναι ευδιάκριτες ως compact clusters στο PCA space, ενώ η BENIGN καταλαμβάνει το πιο πολυποίκιλο γεωμετρικό χώρο.	35
5.4	K-Means $k = 15$ - cluster composition heatmap. Row-normalized: κάθε γραμμή α-θροίζει σε 1, δείχνοντας τι είναι κάθε cluster. Πολλά clusters είναι σχεδόν καθαρά μίας κλάσης ($> 90\%$), ενώ άλλα μοιράζονται μεταξύ similar attack types.	36
5.5	Dendrogram (ward linkage, top 30 merges). Φαίνεται καθαρά διπλή ιεραρχική δομή: ένα μεγάλο σύνολο merges σε χαμηλό height (πορτοκαλί - κανονικό traffic και κοντινά attacks) και ένα απομονωμένο cluster (πράσινο - probably attack patterns που διαφέρουν δραματικά). Η μεγάλη κάθετη γραμμή στο height ~ 800 δείχνει την τελική συγχώνευση των δύο sub-trees.	37
5.6	Hierarchical (average linkage, $k = 15$) - PCA 2-D scatter στο 2.468-row subsample. . .	38
5.7	Hierarchical (average linkage, $k = 15$) - cluster composition heatmap.	38
5.8	k-distance graph ($k = 4$) πάνω σε στρωμένο sample 20.000 rows. Η κύρια καμπύλη παραμένει σχεδόν επίπεδη μέχρι το $\sim 80\%$ percentile και έπειτα εκτοξεύεται απότομα: σαφής αγκώνας στο $\varepsilon \approx 0,3-0,5$, κάτι που επιβεβαιώνει το sweep μας.	39
5.9	DBSCAN ($\varepsilon = 0,3$, <code>min_samples</code> = 20) - PCA 2-D scatter. Τα grey x-markers είναι noise points (12.573 rows, $\sim 9,4\%$ του dataset).	40

Κατάλογος Πινάκων

1.1	Βασικά μεγέθη του CIC-IDS-2017 πριν και μετά την προεπεξεργασία.	8
3.1	Προοδευτική μείωση του μεγέθους του dataset κατά τον καθαρισμό.	15
3.2	Κατανομή των 15 κλάσεων μετά τον καθαρισμό. Το imbalance ratio (max/min) είναι $\approx 195\,173\times$	16
3.3	Top-15 ζεύγη με $ r > 0.997$. Τα 8 πρώτα είναι αλγοριθμικές ταυτότητες του CICFlowMeter.	20
3.4	Τα τρία κριτήρια feature selection και η αιτιολογία τους.	20
3.5	Οι 31 στήλες που αφαιρέθηκαν στο feature selection.	21
3.6	Βασικά αποτελέσματα του Q1.	22
4.1	Logistic Regression - test metrics.	24
4.2	Decision Tree - test metrics.	26
4.3	Random Forest - test metrics.	27
4.4	Q2 - σύγκριση 6 παραλλαγών στο ίδιο test set (26.838 rows).	29
4.5	Βασικά αποτελέσματα του Q2.	32
5.1	K-Means - test metrics στο best k	35
5.2	Hierarchical Clustering - σύγκριση linkage methods ($k = 15$, 2.468-row stratified subsample). Best by both metrics: average linkage.	37
5.3	DBSCAN sweep - όλες οι 15 παραλλαγές. Best silhouette: $\varepsilon = 0,3$, <code>min_samples</code> = 20. Best Davies-Bouldin: $\varepsilon = 1,5$, <code>min_samples</code> = 20. Διαφορετικές μετρικές δίνουν διαφορετικό best - κλασικό clustering trade-off.	39
5.4	Q3 - σύγκριση best configurations ανά αλγόριθμο. <i>Caveat</i> : το Hierarchical εκπαιδεύτηκε σε 2.468-row subsample λόγω $O(n^2)$ memory.	40
5.5	Βασικά αποτελέσματα του Q3.	41

Κεφάλαιο 1

Εισαγωγή

1.1 Πλαίσιο και Κίνητρο

Η ραγδαία αύξηση της εξάρτησης των υποδομών από το διαδίκτυο έχει καταστήσει την **ανίχνευση δικτυακών εισβολών** (Network Intrusion Detection) έναν από τους πιο κρίσιμους τομείς της κυβερνοασφάλειας. Τα σύγχρονα συστήματα ανίχνευσης εισβολών (Intrusion Detection Systems, IDS) δεν μπορούν πλέον να βασίζονται αποκλειστικά σε *signature-based* κανόνες, καθώς οι επιτιθέμενοι προσαρμόζουν συνεχώς τις τεχνικές τους. Αντίθετα, οι προσεγγίσεις που βασίζονται σε **μηχανική μάθηση** (machine learning) μαθαίνουν μοτίβα από ιστορικά δεδομένα δικτυακής ροής και γενικεύουν σε νέες, άγνωστες επιθέσεις.

Η παρούσα εργασία αναπτύσσει ένα ολοκληρωμένο pipeline εξόρυξης δεδομένων πάνω στο **CIC-IDS-2017**, ένα από τα πιο ευρέως χρησιμοποιούμενα δημόσια σύνολα δεδομένων για έρευνα IDS. Το σύνολο περιέχει **2.83 εκατομμύρια** εγγραφές δικτυακής ροής (flow records) καταναμημένες σε μία κανονική κλάση (**BENIGN**) και 14 διαφορετικούς τύπους επιθέσεων, από DDoS και port-scanning μέχρι web attacks και εξαιρετικά σπάνια exploits όπως το Heartbleed.

1.2 Στόχοι Εργασίας

Η εργασία δομείται γύρω από τρία συνδεδεμένα ερωτήματα:

1. **Ερώτημα 1 - Exploratory Data Analysis.** Φόρτωση, καθαρισμός και στατιστική περιγραφή του CIC-IDS-2017. Αντιμέτωπιση Inf/NaN, διπλοτύπων, ανισορροπίας κλάσεων και πολυσυγγραμμικότητας features. Εξαγωγή ενός καθαρού, cached snapshot για επαναχρησιμοποίηση στα Q2 και Q3.
2. **Ερώτημα 2 - Ταξινόμηση.** Εκπαίδευση και σύγκριση τριών αλγορίθμων (Logistic Regression, Decision Tree, Random Forest) με δύο διαφορετικές ρυθμίσεις Grid Search (A και B) για hyperparameter tuning. Αξιολόγηση με macro-F1 και per-class μετρικές λόγω έντονης ανισορροπίας.
3. **Ερώτημα 3 - Συσταδοποίηση.** Εφαρμογή K-Means, Hierarchical Clustering και DBSCAN σε unsupervised mode. Σύγκριση των συστάδων με τις γνωστές ετικέτες (external validation) για να εκτιμηθεί κατά πόσο η δομή των δεδομένων υποστηρίζει ανίχνευση επιθέσεων χωρίς labels.

Η αναφορά αυτή επικεντρώνεται κυρίως στο **Ερώτημα 1**, το οποίο αποτελεί το υπόβαθρο για τα υπόλοιπα δύο. Τα Q2 και Q3 θα προστεθούν ως ξεχωριστά κεφάλαια καθώς ολοκληρώνονται.

1.3 Περιγραφή Δεδομένων

1.3.1 CIC-IDS-2017 Dataset

Το CIC-IDS-2017 δημιουργήθηκε από το Canadian Institute for Cybersecurity (CIC) και κυκλοφορεί ως σύνολο από οκτώ αρχεία CSV, ένα για κάθε ημέρα και χρονική ζώνη της εβδομαδιαίας καταγραφής:

- `Monday-WorkingHours.pcap_ISCX.csv` - μόνο κανονική κίνηση.

- `Tuesday-WorkingHours.pcap_ISCX.csv` - Brute Force (FTP/SSH).
- `Wednesday-workingHours.pcap_ISCX.csv` - DoS (Hulk, GoldenEye, slowloris, Slowhttptest, Heartbleed).
- `Thursday-WorkingHours-Morning-WebAttacks.pcap_ISCX.csv` - Brute Force, XSS, SQL Injection.
- `Thursday-WorkingHours-Afternoon-Infiltration.pcap_ISCX.csv` - Infiltration.
- `Friday-WorkingHours-Morning.pcap_ISCX.csv` - Botnet.
- `Friday-WorkingHours-Afternoon-PortScan.pcap_ISCX.csv` - Port Scan.
- `Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv` - DDoS.

Κάθε γραμμή αντιστοιχεί σε μία *δικτυακή ροή* (flow), δηλαδή μια ακολουθία πακέτων μεταξύ ενός ζεύγους IP/ports για ένα συγκεκριμένο πρωτόκολλο. Τα features έχουν εξαχθεί με το εργαλείο **CICFlowMeter** και περιλαμβάνουν:

- **Βασικά** χαρακτηριστικά: Destination Port, Flow Duration, Total Fwd/Bwd Packets.
- **Στατιστικά μήκους πακέτων**: mean, std, min, max σε forward και backward κατευθύνσεις.
- **Στατιστικά χρονικών διαστημάτων** (Inter-Arrival Times, IAT): Flow IAT Mean/Std/Max/Min, Fwd IAT, Bwd IAT.
- **Flags TCP**: FIN/SYN/RST/PSH/ACK/URG Flag Count.
- **Bulk και subflow** στατιστικά, χαρακτηριστικά active/idle χρόνου.

Η δεύτερη στήλη που αφορά την εργασία είναι το **Label** - η ετικέτα της κλάσης (BENIGN ή όνομα επίθεσης).

1.3.2 Συνοπτικά Μεγέθη

Μέγεθος	Τιμή
Πηγαία αρχεία CSV	8
Αρχικές γραμμές	2.830.743
Αρχικές στήλες	79 (+ Label)
Κλάσεις (συμπ. BENIGN)	15
Μετά από καθαρισμό (γραμμές)	2.572.640
Μετά από feature selection	47 features + Label
Cached Parquet snapshot	221,9 MB

Πίνακας 1.1: Βασικά μεγέθη του CIC-IDS-2017 πριν και μετά την προεπεξεργασία.

1.4 Διάρθρωση της Αναφοράς

Η υπόλοιπη αναφορά οργανώνεται ως εξής:

- **Κεφάλαιο 2 - Θεωρητικό Υπόβαθρο.** Περιγράφονται οι θεμελιώδεις έννοιες που χρησιμοποιούνται σε όλα τα ερωτήματα: preprocessing, class imbalance, Pearson correlation, multicollinearity, κ.α.
- **Κεφάλαιο 3 - Ερώτημα 1: Exploratory Data Analysis.** Λεπτομερής περιγραφή της μεθοδο-

λογίας και των αποτελεσμάτων του Q1.

- **Κεφάλαιο 4 - Ερώτημα 2: Ταξινόμηση.** Εκπαίδευση και αξιολόγηση μοντέλων (θα συμπληρωθεί).
- **Κεφάλαιο 5 - Ερώτημα 3: Συσταδοποίηση.** Unsupervised learning και εξωτερική αξιολόγηση (θα συμπληρωθεί).
- **Κεφάλαιο 6 - Συμπεράσματα και Μελλοντικές Κατευθύνσεις.**
- **Παράρτημα** με οδηγίες εγκατάστασης, εκτέλεσης και αναπαραγωγής.

Κεφάλαιο 2

Θεωρητικό Υπόβαθρο

Σε αυτό το κεφάλαιο συνοψίζονται τα βασικά θεωρητικά εργαλεία που χρησιμοποιούνται στα τρία ερωτήματα. Οι έννοιες παρουσιάζονται όπως εμφανίζονται στο pipeline: από τον καθαρισμό δεδομένων (Q1) μέχρι την ταξινόμηση (Q2) και τη συσταδοποίηση (Q3).

2.1 Προεπεξεργασία Δεδομένων

2.1.1 Missing Values και Infinities

Ένα πραγματικό σύνολο δεδομένων σπάνια είναι πλήρες. Στις δικτυακές μετρήσεις του CIC-IDS-2017 οι *rate* στήλες (*Flow Bytes/s*, *Flow Packets/s*) υπολογίζονται ως διαιρέσεις με τη *Flow Duration*. Όταν η διάρκεια μιας ροής είναι μηδέν μικροδευτερόλεπτα (π.χ. *single-packet flow*), προκύπτουν τιμές $\pm\infty$. Η ανάγνωση αυτών από οποιονδήποτε *StandardScaler*, *RobustScaler* ή από τον ίδιο το *classifier* αποτυγχάνει.

Η τυπική πρακτική είναι:

1. Αντικατάσταση $\pm\infty$ με *NaN* (*df.replace*).
2. Επιλογή μεταξύ **drop rows** ή **imputation**:
 - **Drop**: απλό, διατηρεί την κατανομή, χάνει δεδομένα.
 - **Median imputation**: ανθεκτικό σε outliers, αλλά εισάγει bias σε *rate* στήλες.
 - **Zero imputation**: δηλώνει «μηδενικό throughput», συνήθως λάθος σε flow-based μετρίκες.

Όταν τα missing values είναι $< 1\%$ και σχετίζονται με ανώμαλες παρατηρήσεις (π.χ. μηδενική διάρκεια), η *drop-rows* είναι συνήθως η ασφαλέστερη επιλογή.

2.1.2 Εξαιρετικά Διπλότυπα

Τα exact duplicates δημιουργούν δύο προβλήματα:

- **Πληθωρισμό κλάσεων**: αν χιλιάδες BENIGN γραμμές είναι πανομοιότυπες, το accuracy υπερεκτιμά τη γενικευτική ικανότητα του μοντέλου.
- **Data leakage μεταξύ train/test**: αν μια γραμμή εμφανιστεί και στα δύο split, το μοντέλο «απομνημονεύει» αντί να «μαθαίνει».

Γι' αυτό η αφαίρεση duplicates γίνεται **πριν** από κάθε split και όχι αφού.

2.2 Κλάσεις σε Ανισορροπία

Όταν η αναλογία της μεγαλύτερης προς τη μικρότερη κλάση ξεπερνά το $\sim 10 : 1$, μιλάμε για **imbalanced classification**. Στο CIC-IDS-2017 αυτή η αναλογία είναι $\sim 195\,000 : 1$ (BENIGN vs. Heartbleed), με τρεις άμεσες συνέπειες:

1. **Παραπλανητική accuracy.** Ένας taxonomist «always BENIGN» επιτυγχάνει $\sim 83\%$ χωρίς να ανιχνεύσει ούτε μία επίθεση. Γι' αυτό αναφέρουμε **macro-F1** και **per-class precision/recall**.
2. **Προκατάληψη εκπαίδευσης.** Οι default αλγόριθμοι ελαχιστοποιούν το total loss, άρα ευνοούν τη majority class. Αντίμετρα:
 - **class_weight='balanced'**: αντίστροφα βάρη στο loss.
 - **SMOTE** (Synthetic Minority Over-sampling Technique): synthetic samples για τις minority classes.
 - **Undersampling** της majority class.
3. **Stratified splitting υποχρεωτικό.** Ένα τυχαίο split μπορεί να στείλει όλες τις 11 Heartbleed γραμμές στο training set, αφήνοντας το test σύνολο χωρίς δείγματα για αξιολόγηση. Το **StratifiedShuffle** διατηρεί τα αναλογικά ποσοστά ανά κλάση.

2.3 Pearson Correlation

Ο **συντελεστής συσχέτισης Pearson** μεταξύ δύο μεταβλητών X, Y ορίζεται ως:

$$r_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.1)$$

με $r \in [-1, +1]$. Τιμές ± 1 δηλώνουν τέλεια γραμμική εξάρτηση, $r \approx 0$ καμία γραμμική εξάρτηση (αλλά μπορεί να υπάρχει μη-γραμμική).

2.3.1 Τυφλά Σημεία

Η Pearson έχει τρεις γνωστούς περιορισμούς που είναι χρήσιμοι στην ερμηνεία των αποτελεσμάτων:

- Δεν ανιχνεύει **μη-γραμμικές** σχέσεις (π.χ. $Y = X^2$ δίνει $r \approx 0$).
- Είναι ιδιαίτερα ευαίσθητη σε **outliers**, ειδικά σε κατανομές heavy-tailed.
- Απαιτεί **αριθμητικές** μεταβλητές. Το label encoding που εφαρμόζουμε στο **Label** επιβάλλει αυθαίρετη διάταξη, οπότε η **corrwith(Label)** είναι μόνο *ενδεικτική*. Για αυστηρή αξιολόγηση feature importance χρησιμοποιείται **mutual information** ή tree-based importance.

2.4 Multicollinearity

Δύο features με $|r| \rightarrow 1$ μεταφέρουν την ίδια πληροφορία. Η **πολυσυγγραμμικότητα** (multicollinearity) βλάπτει τα μοντέλα με τρεις τρόπους:

1. **Γραμμικά μοντέλα** (Logistic Regression): οι συντελεστές γίνονται ασταθείς. Με δύο σχεδόν πανομοιότυπα features, ο αλγόριθμος μπορεί να δώσει $w_1 = +10$, $w_2 = -10$ ή $w_1 = +5$, $w_2 = -5$, μαθηματικά ισοδύναμα αλλά ανερμήνευτα. Η τυπική απόκλιση των coefficients εκρήγνυται.
2. **Αλγόριθμοι βασισμένοι σε αποστάσεις** (K-Means, KNN, DBSCAN): η επανειλημμένη διάσταση μετράει διπλά στην ευκλείδεια απόσταση, οπότε αυτή η διάσταση κυριαρχεί τεχνητά.
3. **Υπολογιστικά**: περισσότερες στήλες σημαίνει πιο αργή εκπαίδευση χωρίς κέρδος πληροφορίας.

Η στρατηγική που ακολουθούμε είναι να κρατήσουμε μία μόνο στήλη ανά cluster υψηλής συσχέτισης (με threshold $|r| > 0.95$), διατηρώντας την πρώτη στη σειρά των στηλών και πετώντας τις άλλες.

2.5 log1p Transform και Skewness

Πολλά features του CIC-IDS-2017 εκτείνονται σε πολλές τάξεις μεγέθους (π.χ. **Flow Duration** από μς έως λεπτά) και έχουν $\text{skewness} > 100$ με kurtosis στις χιλιάδες. Χωρίς μετασχηματισμό, τα ιστογράμματα συμπύσσονται σε μία κορυφή κοντά στο 0 με λεπτή ουρά και οι boxplots είναι οπτικά άχρηστα.

Ο μετασχηματισμός **log1p**:

$$\text{log1p}(x) = \log(1 + x) \quad (2.2)$$

έχει τρία πλεονεκτήματα:

- Είναι ασφαλής για $x = 0$ (ενώ $\log(0) \rightarrow -\infty$).
- Για μεγάλα x , $\text{log1p}(x) \approx \log(x)$.
- Για μικρά x , η Taylor expansion δίνει $\text{log1p}(x) \approx x$.

2.6 Stratified Sampling για Οπτικοποίηση

Για ένα dataset με ~ 2.57 εκατομμύρια γραμμές, το KDE και τα heatmaps γίνονται απαγορευτικά αργά. Η στρατηγική μας είναι:

- **Στατιστικά** (`describe`, correlation matrix): ολόκληρο το dataset. Δεν υπάρχει λόγος να θυσιάσουμε ακρίβεια.
- **Οπτικοποιήσεις**: stratified sample 50 000 γραμμών με `StratifiedShuffleSplit`, ώστε κάθε κλάση (ακόμα και η Heartbleed με 11 γραμμές) να εκπροσωπείται.

2.7 Αξιολόγηση Ταξινομητών (Q2)

2.7.1 Confusion Matrix

Για multi-class classification με C κλάσεις, η confusion matrix $M \in \mathbb{N}^{C \times C}$ ορίζεται ως M_{ij} = πλήθος δειγμάτων με πραγματική κλάση i που ταξινομήθηκαν στην κλάση j . Η διαγώνιος είναι τα σωστά (TP ανά κλάση).

2.7.2 Precision, Recall, F1

Για κάθε κλάση c :

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \quad (2.3)$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}, \quad (2.4)$$

$$F1_c = 2 \cdot \frac{\text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}. \quad (2.5)$$

Το **macro-F1** είναι ο αστάθμιστος μέσος όρος των $F1_c$ - κάθε κλάση μετράει το ίδιο, ανεξάρτητα από το μέγεθός της. Το **weighted-F1** σταθμίζει με το support, επομένως υπερεκτιμά τα μοντέλα που τα πάνε καλά στη majority class.

2.7.3 Grid Search Cross-Validation

Το `GridSearchCV` εξαντλητικά δοκιμάζει όλους τους συνδυασμούς hyperparameters σε k -fold cross-validation (συνήθως $k = 5$). Η **stratified** παραλλαγή διατηρεί την κατανομή των κλάσεων σε κάθε fold, κρίσιμο για imbalanced data.

2.8 Συσταδοποίηση (Q3)

2.8.1 K-Means

Ο αλγόριθμος K-Means ελαχιστοποιεί την εντός-συστάδας διασπορά (inertia):

$$\min_{\{C_k\}, \{\mu_k\}} \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2. \quad (2.6)$$

Επιλογή του K : elbow method (inertia vs K) ή silhouette score.

2.8.2 DBSCAN

Σε αντίθεση με το K-Means, το DBSCAN δεν απαιτεί προκαθορισμένο K , βρίσκει συστάδες αυθαίρετου σχήματος και χαρακτηρίζει σημεία ως **noise** αν δεν ανήκουν σε κάποια πυκνή περιοχή. Ορίζεται από δύο παραμέτρους:

- ϵ (eps): ακτίνα γειτονιάς.
- `min_samples`: ελάχιστα σημεία σε μια πυκνή περιοχή.

2.8.3 Hierarchical Clustering

Κατασκευάζει ένα δενδρόγραμμα (dendrogram) συγχωνεύοντας επαναληπτικά τα πιο κοντινά σημεία/συστάδες. Η linkage function (single, complete, average, Ward) καθορίζει πώς μετράται η απόσταση μεταξύ συστάδων.

2.8.4 External Validation με ARI

Όταν οι *πραγματικές* ετικέτες είναι γνωστές (όπως εδώ), μπορούμε να αξιολογήσουμε τις συστάδες με **Adjusted Rand Index (ARI)** ή **Normalized Mutual Information (NMI)**. Αυτό μας λέει πόσο καλά η δομή των δεδομένων αντιστοιχεί στις κλάσεις επίθεσης, χωρίς να έχει χρησιμοποιηθεί καμία ετικέτα κατά την εκπαίδευση.

Κεφάλαιο 3

Ερώτημα 1: Exploratory Data Analysis

3.1 Επισκόπηση του Pipeline

Το Q1 υλοποιήθηκε ως ένα μοναδικό Jupyter notebook (`notebooks/q1_eda.ipynb`), εύκολα επανεκτελέσιμο μέσω `nbconvert`. Το pipeline που ακολουθεί είναι αυτό:

1. Φόρτωση όλων των 8 CSV αρχείων και συγχώνευσή τους.
2. Κανονικοποίηση ονομάτων στηλών και ετικετών.
3. Αντιμετώπιση `Inf` και `NaN`.
4. Αφαίρεση duplicates.
5. Περιγραφικά στατιστικά και οπτικοποίηση κατανομής κλάσεων.
6. Ιστογράμματα, boxplots, correlation heatmap.
7. Feature selection (zero-variance + high-correlation).
8. Αποθήκευση σε Parquet για επαναχρησιμοποίηση από Q2/Q3.

3.2 Φόρτωση και Επισκόπηση

3.2.1 Ενοποίηση των 8 CSV

Η βοηθητική συνάρτηση `load_cic_ids_2017` (αρχείο `utils/helpers.py`) διαβάζει ένα προς ένα τα 8 CSV αρχεία με `encoding='latin1'` για να αντιμετωπίσει τα corrupted bytes στα labels των Web Attacks, κάνει concatenation και κρατά προέλευση μέσω της στήλης `__source_file` (αφαιρείται αργότερα).

```
● ● ● Φόρτωση Dataset
1 from utils.helpers import load_cic_ids_2017, RANDOM_STATE
2 import numpy as np, pandas as pd
3
4 df = load_cic_ids_2017()
5 print(df.shape) # (2830743, 80)
```

Μέσα στη `_standardize_columns` γίνεται και ένα κρίσιμο βήμα: η στήλη `Fwd Header Length.1` - ένα αντίγραφο της `Fwd Header Length` που εξάγει λανθασμένα το CICFlowMeter - αφαιρείται αυτόματα.

3.2.2 Καθαρισμός Ετικετών

Οι ετικέτες των Web Attacks στα raw CSV περιέχουν το χαρακτήρα `U+FFFD` (το Unicode replacement character) στη θέση ενός en-dash: "Web Attack `□` Brute Force". Η `_clean_labels` τα κα-

νονικοποιεί σε "Web Attack Brute Force", "Web Attack XSS", "Web Attack Sql Injection".

3.3 Καθαρισμός Δεδομένων

3.3.1 Infinities και Missing Values

Οι στήλες Flow Bytes/s και Flow Packets/s περιέχουν 4 376 τιμές $\pm\infty$ (από διαίρεση με Flow Duration=0). Ακολουθούμε τη στρατηγική replace-&-drop:

```

1 from utils.helpers import handle_infinities
2
3 df = handle_infinities(df) # (+/-inf) -> NaN
4 print(df.isna().sum().sum()) # 4376 NaN total
5 before = len(df)
6 df = df.dropna().reset_index(drop=True)
7 print(before - len(df), "rows dropped") # 2867 rows

```

Το αποτέλεσμα είναι **2.867** γραμμές που αφαιρέθηκαν, δηλαδή 0.101% του dataset - ποσοστό πολύ μικρό για να επηρεάσει τη δομή.

3.3.2 Duplicates

Η `drop_duplicates_report` αναφέρει **255.236** exact duplicates ($\sim 9\%$ μετά το NaN handling). Αυτά αφαιρούνται *πριν* το οποιοδήποτε split, ώστε το test set του Q2 να είναι πραγματικά unseen.

Στάδιο	Γραμμές	Διαφορά
Αρχικό	2.830.743	—
Μετά drop NaN	2.827.876	−2 867
Μετά drop dup	2.572.640	−255 236


Πίνακας 3.1: Προοδευτική μείωση του μεγέθους του dataset κατά τον καθαρισμό.

3.4 Κατανομή Κλάσεων

Η κατανομή των 15 κλάσεων φαίνεται στον Πίνακα 3.2 και οπτικοποιείται στο Σχήμα 3.1.

Κλάση	Πλήθος	Ποσοστό
BENIGN	2.146.899	83,45%
DoS Hulk	172.846	6,72%
DDoS	128.014	4,98%
PortScan	90.694	3,53%
DoS GoldenEye	10.286	0,40%
FTP-Patator	5.931	0,23%
DoS slowloris	5.385	0,21%
DoS Slowhttptest	5.228	0,20%
SSH-Patator	3.219	0,13%
Bot	1.948	0,08%
Web Attack Brute Force	1.470	0,06%
Web Attack XSS	652	0,03%
Infiltration	36	0,0014%
Web Attack Sql Injection	21	0,0008%
Heartbleed	11	0,0004%
Σύνολο	2.572.640	100%

Πίνακας 3.2: Κατανομή των 15 κλάσεων μετά τον καθαρισμό. Το imbalance ratio (max/min) είναι $\approx 195\,173\times$.



Σχήμα 3.1: Κατανομή κλάσεων στο καθαρισμένο CIC-IDS-2017. Το αριστερό σχήμα χρησιμοποιεί λογαριθμικό άξονα ώστε να φαίνονται και οι σπάνιες κλάσεις (Heartbleed, Sql Injection, Infiltration).

Παρατηρήσεις. Η ακραία ανισορροπία (η BENIGN είναι $> 195\,000\times$ πιο συχνή από την Heartbleed) καθορίζει τις επιλογές του Q2: θα απαιτηθεί `class_weight="balanced"`, macro-F1 ως κύρια metric και stratified splitting.

3.5 Περιγραφικά Στατιστικά


Για κάθε αριθμητική στήλη υπολογίστηκαν mean, median, std, min, 25%, 50%, 75%, max, skewness και kurtosis. Τα πλήρη αποτελέσματα αποθηκεύτηκαν στο `outputs/results/q1_describe.csv`. Τα βασικά ευρήματα:

- Πολλές στήλες έχουν **skewness** > 100 και **kurtosis** στις χιλιάδες - επιβεβαιώνοντας κατανομές heavy-tailed που απαιτούν log-transform για οπτικοποίηση.
- Οι στήλες Fwd Avg Bytes/Bulk, Bwd Avg Packets/Bulk κ.ά. έχουν **std=0**, δηλαδή είναι **σταθερές** σε όλες τις $\sim 2.57M$ γραμμές και θα αφαιρεθούν στο βήμα feature selection.

3.6 Οπτικοποιήσεις

3.6.1 Ιστογράμματα Top Features


Επιλέχθηκαν 20 features με τη μεγαλύτερη διασπορά για plot. Για λόγους ευκρίνειας ο άξονας x είναι σε log scale ($\log_{10}$) και το KDE υπολογίστηκε σε stratified sample 50 000 γραμμών.



Σχήμα 3.2: Ιστογράμματα με KDE για τις 20 στήλες μεγαλύτερης διασποράς ($\log_{10}$ scale). Οι περισσότερες κατανομές είναι έντονα λοξές και heavy-tailed.

3.6.2 Boxplots

Οι boxplots (Σχήμα 3.3) αποκαλύπτουν έντονα «νέφοι» outliers στις rate και duration στήλες. Αυτά δεν είναι «θόρυβος» προς αφαίρεση - είναι ακριβώς η υπογραφή των DDoS/DoS επιθέσεων (πολύ υψηλά throughput, πολύ μακριές διάρκειες).



Σχήμα 3.3: Boxplots (log1p scale) για τις 20 στήλες μεγαλύτερης διασποράς. Τα outliers πάνω από τα whiskers είναι διαγνωστικά για επιθέσεις DoS/DDoS και δεν αφαιρούνται.

3.6.3 Correlation Heatmap

Η Pearson correlation matrix (77×77) οπτικοποιείται ως heatmap (Σχήμα 3.4). Τα βαθυκόκκινα και βαθυγάλανα τετράγωνα είναι τα ζεύγη που θα στοχεύσουμε στο feature selection.

Feature A	Feature B	r
Bwd Packet Length Mean	Avg Bwd Segment Size	1,0000
Total Fwd Packets	Subflow Fwd Packets	1,0000
Total Backward Packets	Subflow Bwd Packets	1,0000
Fwd URG Flags	CWE Flag Count	1,0000
Fwd Packet Length Mean	Avg Fwd Segment Size	1,0000
Fwd PSH Flags	SYN Flag Count	1,0000
Total Length of Bwd Packets	Subflow Bwd Bytes	1,0000
Total Length of Fwd Packets	Subflow Fwd Bytes	1,0000
Total Backward Packets	Subflow Fwd Packets	0,9991
Subflow Fwd Packets	Subflow Bwd Packets	0,9991
Total Fwd Packets	Subflow Bwd Packets	0,9991
Total Fwd Packets	Total Backward Packets	0,9991
Flow Duration	Fwd IAT Total	0,9985
Flow IAT Max	Fwd IAT Max	0,9981
Packet Length Mean	Average Packet Size	0,9978

Πίνακας 3.3: Top-15 ζεύγη με $|r| > 0.997$. Τα 8 πρώτα είναι αλγοριθμικές ταυτότητες του CICFlowMeter.

3.6.5 Correlation με το Label

Καμία στήλη δεν έχει $|r| > 0.31$ με το label (εξαρτώμενο από label encoding), επιβεβαιώνοντας ότι το πρόβλημα είναι γνήσια πολυμεταβλητό. Οι 5 πιο σχετικές στήλες είναι **Fwd IAT Std** (0,30), **Idle Mean** (0,28), **Bwd Packet Length Std** (0,28), **Idle Max** (0,28), **Idle Min** (0,28).

Σημείωση: Τέσσερα από τα παραπάνω πέντε features (**Idle Mean/Max/Min**, **Bwd Packet Length Std**) θα αφαιρεθούν στην επόμενη ενότητα ως υψηλά συσχετισμένα. Αυτό δεν αφαιρεί πληροφορία: ανήκουν στο ίδιο cluster με features που διατηρούνται (π.χ. **Flow IAT Max** με $r = 0,276$ προς το label, που εκπροσωπεί τη ομάδα **Idle/IAT-Max**). Έτσι ο επόμενος ταξινομητής βλέπει την ίδια διακριτική σήμανση μέσω του εκπροσώπου της κάθε ομάδας.

3.7 Feature Selection

3.7.1 Κριτήρια Αφαίρεσης

Εφαρμόσαμε τρία κριτήρια, με την ακόλουθη σειρά:

Κριτήριο	Αιτιολογία
Bookkeeping	Βοηθητικές στήλες (<code>__source_file</code>) που δεν είναι feature.
Zero variance ($\sigma^2 = 0$)	Σταθερές στήλες: καμία πληροφορία, καταρρίπτουν κάθε scaler/model.
High correlation ($ r > 0.95$)	Multicollinear near-duplicates: κρατάμε μία ανά cluster.

Πίνακας 3.4: Τα τρία κριτήρια feature selection και η αιτιολογία τους.

3.7.2 Αποτελέσματα

Συνολικά αφαιρέθηκαν **31 στήλες** (Πίνακας 3.5):

- **1** bookkeeping (`__source_file`).
- **8** zero-variance: όλες οι Bulk-rate (Fwd/Bwd Avg Bytes/Bulk, .../Packets/Bulk, .../Bulk Rate) και Bwd PSH Flags, Bwd URG Flags. Όλες είναι μηδενικές σε όλα τα $\sim 2.57M$ flows.
- **22** highly correlated: αλγοριθμικές ταυτότητες του CICFlowMeter και near-duplicates (Average Packet Size, Avg Bwd Segment Size, Subflow Fwd Packets, κλπ.).

Στήλη	Λόγος
<code>__source_file</code>	bookkeeping / non-feature helper column
Bwd PSH Flags	zero variance (constant)
Bwd URG Flags	zero variance (constant)
Fwd Avg Bytes/Bulk	zero variance (constant)
Fwd Avg Packets/Bulk	zero variance (constant)
Fwd Avg Bulk Rate	zero variance (constant)
Bwd Avg Bytes/Bulk	zero variance (constant)
Bwd Avg Packets/Bulk	zero variance (constant)
Bwd Avg Bulk Rate	zero variance (constant)
Average Packet Size	highly correlated ($ r > 0.95$) with a kept feature
Avg Bwd Segment Size	highly correlated ($ r > 0.95$)
Avg Fwd Segment Size	highly correlated ($ r > 0.95$)
Bwd Packet Length Mean	highly correlated ($ r > 0.95$)
Bwd Packet Length Std	highly correlated ($ r > 0.95$)
CWE Flag Count	highly correlated ($ r > 0.95$)
ECE Flag Count	highly correlated ($ r > 0.95$)
Fwd IAT Max	highly correlated ($ r > 0.95$)
Fwd IAT Total	highly correlated ($ r > 0.95$)
Fwd Packet Length Std	highly correlated ($ r > 0.95$)
Fwd Packets/s	highly correlated ($ r > 0.95$)
Idle Max	highly correlated ($ r > 0.95$)
Idle Mean	highly correlated ($ r > 0.95$)
Idle Min	highly correlated ($ r > 0.95$)
Packet Length Std	highly correlated ($ r > 0.95$)
SYN Flag Count	highly correlated ($ r > 0.95$)
Subflow Bwd Bytes	highly correlated ($ r > 0.95$)
Subflow Bwd Packets	highly correlated ($ r > 0.95$)
Subflow Fwd Bytes	highly correlated ($ r > 0.95$)
Subflow Fwd Packets	highly correlated ($ r > 0.95$)
Total Backward Packets	highly correlated ($ r > 0.95$)
Total Length of Bwd Packets	highly correlated ($ r > 0.95$)

Πίνακας 3.5: Οι 31 στήλες που αφαιρέθηκαν στο feature selection.

3.7.3 Τελική Λίστα Features

Μετά το feature selection έχουμε **47 features + Label** (48 στήλες συνολικά), οι οποίες αποθηκεύτηκαν στο `outputs/results/q1_final_feature_list.csv`. Ενδεικτικά, οι πρώτες δέκα: Destination Port, Flow Duration, Total Fwd Packets, Total Length of Fwd Packets, Fwd Packet Length Max, Fwd Packet Length Min, Fwd Packet Length Mean, Bwd Packet Length Max, Bwd Packet Length Min, Flow Bytes/s.

3.8 Αποθήκευση του Clean Snapshot

Το καθαρισμένο dataset σώζεται σε Parquet (`data/cic_ids_2017_clean.parquet`, 221,9 MB) μέσω της `save_clean_cached`. Τα Q2 και Q3 το φορτώνουν άμεσα με `load_clean_cached()` χωρίς να επαναλάβουν το pipeline.

Γιατί Parquet και όχι CSV:

- **Columnar storage:** αν το Q3 θέλει μόνο 10 στήλες, τις διαβάζει χωρίς να φορτώσει τις υπόλοιπες 38.
- **Compressed:** 221,9 MB αντί για ~900 MB σε CSV.
- **Type-preserved:** διατηρεί τα int32/float32 που προσεκτικά ορίσαμε στη `_optimize_memory`.
- **Fast I/O:** τα Q2/Q3 φορτώνουν σε < 2 sec αντί για ~ 60 sec CSV parsing.

3.9 Σύνοψη Q1

Μέγεθος	Τιμή
Αρχικές γραμμές	2.830.743
Rows με $\pm\infty \rightarrow \text{NaN}$	4.376 (τιμές)
Rows που έπεσαν λόγω NaN	2.867 (0, 101%)
Exact duplicates που αφαιρέθηκαν	255.236 ($\sim 9\%$)
Τελικές γραμμές	2.572.640
Αρχικές στήλες	79 + Label
Στήλες που αφαιρέθηκαν	31
Τελικές στήλες	47 + Label
Κλάσεις	15
Imbalance ratio (max/min)	$\sim 195\,173\times$
Parquet snapshot	221,9 MB

Πίνακας 3.6: Βασικά αποτελέσματα του Q1.

Κεφάλαιο 4

Ερώτημα 2: Ταξινόμηση

Στο κεφάλαιο αυτό εκπαιδεύουμε τρεις ταξινομητές (Logistic Regression, Decision Tree, Random Forest) στο καθαρισμένο dataset του Q1 και τους αξιολογούμε με δύο διαφορετικά πρωτόκολλα hyperparameter selection: (α) *Σενάριο A* - held-out validation set σε stratified split 60/20/20, και (β) *Σενάριο B* - 5-fold Stratified CV μέσω GridSearchCV πάνω στο 80% training, με το ίδιο test set σε όλες τις παραλλαγές.

4.1 Μεθοδολογία

4.1.1 Stratified Subsampling με Per-Class Cap

Το πλήρες cleaned dataset έχει 2.572.640 γραμμές. Για να γίνει υπολογιστικά εφικτή η εξαντλητική grid search (ιδίως για το Random Forest με $18 \text{ combinations} \times 5 \text{ CV folds}$), εφαρμόζουμε **stratified subsampling με per-class cap** στις 25.000 rows. Οι μειονοτικές κλάσεις (Heartbleed = 11, SQL Injection = 21, Infiltration = 36, ...) διατηρούνται **πλήρως** - το cap ενεργοποιείται μόνο για τις τέσσερις τεράστιες (BENIGN, DoS Hulk, DDoS, PortScan).

Συνέπεια στο imbalance. Το imbalance ratio πέφτει από 195 173:1 στο raw data σε $\sim 2\,272:1$ (25.000 BENIGN έναντι 11 Heartbleed). Παραμένει αρκετά σοβαρό ώστε το `class_weight="balanced"` να διατηρεί το νόημά του· η παρακολούθηση macro-F1 συνεχίζει να είναι απαραίτητη για να αντληθούμε την ποιότητα στις rare classes.

Τελικό μέγεθος: 134.187 rows $\times$ 47 features + Label.

Configurable mode. Στο notebook υπάρχει ορισμένη μεταβλητή SUBSAMPLE_CAP με τρία πρακτικά presets: 25_000 (fast, $\sim 134\text{K}$ rows, $\sim 15\text{-}25$ min - default που αναφέρεται εδώ), 100_000 (medium, $\sim 500\text{K}$ rows, $\sim 2\text{-}4$ hours) και None (full dataset, $\sim 2,5\text{M}$ rows, $\sim 12+$ hours σε σύγχρονο laptop). Ο κύριος bottleneck στο full mode είναι το LR με saga solver, που μπορεί να χρειαστεί 1-3 ώρες ανά grid combination.

4.1.2 Encoding, Scaling και Imbalance Handling

- **LabelEncoder** στο target: μετατρέπει τα 15 string labels σε ακραίους $[0, 14]$, όπως περιμένουν οι multi-class classifiers του scikit-learn. One-hot δεν έχει νόημα στο target (θα γινόταν multi-output regression).
- **StandardScaler μέσα σε Pipeline** για το Logistic Regression. Το pipeline εξασφαλίζει ότι ο scaler γίνεται `fit` μόνο στο training fold σε κάθε CV split - αποφεύγοντας data leakage. Για Decision Tree και Random Forest παραλείπεται: τα splits του δέντρου είναι invariant σε monotonic transforms του feature.
- **class_weight="balanced"** σε κάθε αλγόριθμο. Ζυγίζει κάθε row με $n/(C \cdot n_c)$ όπου n το σύνολο, C ο αριθμός κλάσεων και n_c η συχνότητα της κλάσης. Χωρίς αυτό, ένας classifier θα έβγαζε $\sim 80\%$ accuracy απλώς προβλέποντας πάντα BENIGN. Εναλλακτικές (SMOTE, undersampling) εγκυμονούν data-leakage risks αν δεν εφαρμοστούν per-fold.

4.1.3 Πρωτόκολλο Splits

Το subsampled dataset σπάει σε δύο βήματα:

1. Stratified 80/20 $\rightarrow$ `trainval` / `test`. Το `test` (26.838 rows) είναι ο **τυφλός μάρτυρας**: αγγίζεται μόνο για το final reporting και των δύο σεναρίων.
2. Από το `trainval` σπάμε ξανά stratified 75/25 $\rightarrow$ `train` (80.511 rows) / `val` (26.838 rows). Αυτό δίνει τον τελικό 60/20/20 λόγο που ζητά η εκφώνηση.
 - **Σενάριο A** (split-based grid search): για κάθε combination στο grid, fit σε `train`, score σε `val` με F1-weighted. Επιλέγουμε best params, refit στο `trainval`, evaluate στο `test`.
 - **Σενάριο B** (5-fold StratifiedKfold μέσω `GridSearchCV`) πάνω στο ίδιο `trainval` και ίδιο grid. Best params $\rightarrow$ refit στο `trainval`, evaluate στο `test`.

Το κοινό `test` σε κάθε παραλλαγή είναι αυτό που καθιστά δυνατή τη μεταξύ τους σύγκριση.

4.1.4 Scoring Metric για την Επιλογή Hyperparameters

Χρησιμοποιούμε **F1-weighted** και στα δύο σενάρια. Στο final reporting εμφανίζουμε και F1-macro. Λόγοι:

- **Accuracy** εξαπατά σε imbalanced multi-class ($\sim 80\%$ απλώς από το να προβλέπει BENIGN πάντα).
- **F1-macro** δίνει ίσο βάρος σε κάθε κλάση, αλλά οι rare κλάσεις (Heartbleed = 11 rows) έχουν τέτοια variance ώστε να ταλαντώνεται έντονα κατά τη διαδικασία selection.
- **F1-weighted** ζυγίζει κάθε κλάση με τη support της - είναι default για multi-class στο scikit-learn, και σταθερότερη μετρική για hyperparameter selection.

Το F1-macro κρατιέται ως *μετρική αναφοράς* για να κρίνουμε αν το μοντέλο απλώς «μαθαίνει τις μεγάλες κλάσεις» ή αν πιάνει και τις rare attacks.

4.2 Logistic Regression

Διαίσθηση. Γραμμικός classifier, softmax για multi-class: μία γραμμική λειτουργία ανά κλάση, normalized να αθροίζουν σε 1. Η απόφαση χωρίζεται από *υπερεπίπεδα* στο feature space. Καλός baseline: ταχύτατο, ερμηνεύσιμο (coefficients), δίνει calibrated probabilities. Περιορισμοί: υποθέτει γραμμική σχέση features $\rightarrow$ log-odds, ευαίσθητο σε scale, δεν πιάνει αλληλεπιδράσεις features.

Grid. 16 combinations:

$$C \in \{0.01, 0.1, 1, 10\}, \quad \text{solver} \in \{\text{lbfgs}, \text{saga}\}, \quad \text{max_iter} \in \{200, 500\}.$$


Αποτέλεσμα. Και στα δύο σενάρια επιλέγονται τα ίδια hyperparameters: $C = 10$, `solver=lbfgs`, `max_iter = 500`. Η σύγκλιση των δύο σεναρίων δείχνει ότι το validation set των 26.838 rows είναι αρκετά μεγάλο ώστε να συμφωνήσει με τον CV μέσο όρο. Το metrics όπως το βλέπουμε στο test:

Σενάριο	Accuracy	Precision _w	Recall _w	F1 _w	F1 _m
A (split)	0,9595	0,9750	0,9595	0,9647	0,7810
B (CV)	0,9595	0,9750	0,9595	0,9647	0,7810

Πίνακας 4.1: Logistic Regression - test metrics.

Το F1-weighted = 0,965 ακούγεται εξαιρετικό αλλά το F1-macro = 0,781 αποκαλύπτει την αδυναμία: το LR αποτυγχάνει στις non-linearly separable κλάσεις. Όπως αναμέναμε, γραμμικά υπερεπίπεδα δεν αρκούν για να ξεχωρίσουν Web-Attack υπογραφές μέσα σε BENIGN HTTP traffic.

Συντελεστές του LR. Το multinomial LR παράγει έναν πίνακα συντελεστών shape $(n_{\text{classes}}, n_{\text{features}})$. Κάθε row δείχνει πόσο σπρώχνει κάθε feature ένα sample προς (θετικό πρόσημο) ή μακριά από (αρνητικό) την κλάση. Σε αντίθεση με τα tree-based feature importances, οι LR συντελεστές δίνουν *direction*, όχι μόνο *magnitude* - αυτό είναι το ερμηνεύσιμο πλεονέκτημα του LR.




Σχήμα 4.1: Logistic Regression (Σενάριο B) - heatmap των συντελεστών για τα top-15 features (κατά μέσο |coef| σε όλες τις κλάσεις). Έντονο κόκκινο = το feature οδηγεί strongly προς αυτή την κλάση· έντονο μπλε = αντενδείκνυται. Παράδειγμα: η **PortScan** έχει σαφώς θετικούς συντελεστές στα **Bwd Packet Length Min** και **Bwd Packets/s** (μικρά backward packets σε υψηλό rate - υπογραφή scanning).

4.3 Decision Tree

Διαίσθηση. Ακολουθία **if/else** ερωτήσεων· σε κάθε κόμβο επιλέγουμε feature+threshold που μεγιστοποιεί το *information gain* (μείωση impurity). Τα criteria που συγκρίνουμε:

- **Gini impurity:** $1 - \sum_c p_c^2$. Πιθανότητα λανθασμένης ταξινόμησης αν βάλουμε τυχαία row στο πιο συχνό class.
- **Entropy:** $-\sum_c p_c \log_2 p_c$. Information- theoretic measure - πόσα bits χρειάζονται για να περιγράψουμε την κλάση.

Regularization μέσω **max_depth** (upper bound) και **min_samples_split** (lower bound μεγέθους κόμβου). Δεν απαιτείται scaling.



Σχήμα 4.3: Standalone shallow Decision Tree (max_depth = 3, entropy) εκπαιδευμένο ξεχωριστά για clean visualization. Όχι το best model - απλώς δείχνει πώς θα μοιάζει ένα ολόκληρο δέντρο 3 επιπέδων.

4.4 Random Forest

Διαίσθηση. Ensemble από πολλά δέντρα που διαφέρουν μεταξύ τους μέσω:

1. **Bagging:** κάθε δέντρο εκπαιδεύεται σε ένα bootstrap sample του training set (με replacement).
2. **Feature randomness:** σε κάθε split, εξετάζεται μόνο ένα τυχαίο υποσύνολο features (default $\sqrt{n}$).

Ένα μεμονωμένο δέντρο είναι high-variance· ο μέσος όρος πολλών στατιστικά ανεξάρτητων δέντρων μειώνει τη variance χωρίς να αυξάνει το bias. Επίσης, δεν υπερ-εμπιστεύεται κανένα μεμονωμένο feature. Δεν απαιτείται scaling.

Grid. 18 combinations:

$$n_estimators \in \{50, 100, 200\}, \max_depth \in \{10, 20, \text{None}\}, \min_samples_split \in \{2, 10\}.$$


Αποτελέσματα. Σενάριο A επιλέγει $n_estimators = 100$, $\max_depth = 20$, $\min_samples_split = 2$. Σενάριο B επιλέγει $n_estimators = 100$, $\max_depth = \text{None}$, $\min_samples_split = 2$.

Σενάριο	Accuracy	Precision _w	Recall _w	F1 _w	F1 _m
A (split)	0,9920	0,9920	0,9920	0,9920	0,9116
B (CV)	0,9925	0,9920	0,9925	0,9921	0,9062

Πίνακας 4.3: Random Forest - test metrics.

Το F1-weighted είναι οριακά καλύτερο σε B (0,9921 vs 0,9920), ενώ το F1-macro είναι καλύτερο σε A (0,9116 vs 0,9062). Αυτό είναι ενδιαφέρον: η CV επιλέγει με βάση F1-weighted (κατά convention στο GridSearchCV), επομένως δεν εγγυάται τη βέλτιστη macro απόδοση. Σε ένα production IDS που απαιτεί ισχυρή ανίχνευση rare attacks, θα εναλλάσσαμε το scoring σε F1-macro.


Feature importance. Σε αντίθεση με τον DT, το RF κατανέμει το importance: top-5 είναι **Destination Port** (0,073), **Init_Win_bytes_backward** (0,057), **Fwd Packet Length Max** (0,045), **Bwd Packets/s** (0,045), **Packet Length Mean** (0,041). Δεν υπάρχει ένα feature-«μονάρχης»· τα επόμενα 15 features έχουν παρόμοιες τιμές. Αυτή η εξισορρόπηση είναι το signature του bagging/feature-randomness averaging.



Σχήμα 4.4: Top-20 feature importances του Random Forest (Σενάριο B).

Visualization ενός voter του δάσους. Το Σχ. 4.5 δείχνει τα top-3 levels ενός μεμονωμένου δέντρου από το best RF (δέντρο #0 από τα 100). Σημειώνουμε ότι:

- Το πρώτο split εδώ είναι **Bwd Packet Length Max** - διαφορετικό από το πρώτο split του standalone DT (**Destination Port**). Αυτό είναι ακριβώς το diversity που επιδιώκουμε με bagging+feature-randomness.
- Αν δείχναμε ένα δεύτερο δέντρο (π.χ. `tree_index=1`), η δομή θα ήταν ξανά διαφορετική.
- Η τελική πρόβλεψη του RF είναι *majority vote* (ή average των per-tree probabilities) πάνω σε όλα τα 100 δέντρα. Άρα ένα μεμονωμένο tree δεν αντιπροσωπεύει την «απόφαση» του RF.




Σχήμα 4.5: Random Forest (Σενάριο B) - top 3 levels του πρώτου voter του δάσους (από τα 100 δέντρα συνολικά). Τα splits εδώ διαφέρουν από αυτά του standalone DT - σημείο της feature randomness που επιβάλλει το RF.

4.5 Συγκριτική Ανάλυση

Model	Σενάριο	Acc	Prec _w	Rec _w	F1 _w	F1 _m
Logistic Regression	A	0,9595	0,9750	0,9595	0,9647	0,7810
Logistic Regression	B	0,9595	0,9750	0,9595	0,9647	0,7810
Decision Tree	A	0,9918	0,9930	0,9918	0,9920	0,9093
Decision Tree	B	0,9921	0,9920	0,9921	0,9920	0,9097
Random Forest	A	0,9920	0,9920	0,9920	0,9920	0,9116
Random Forest	B	0,9925	0,9920	0,9925	0,9921	0,9062

Πίνακας 4.4: Q2 - σύγκριση 6 παραλλαγών στο ίδιο test set (26.838 rows).



Σχήμα 4.6: F1-weighted έναντι F1-macro και για τις 6 παραλλαγές. Η διαφορά $F1_w - F1_m$ είναι η «υπογραφή του imbalance»: πόσο «χρωστά» το μοντέλο την απόδοσή του στις μεγάλες κλάσεις.

4.5.1 Απαντήσεις στις Τέσσερις Ερωτήσεις της Εκφώνησης

1. Ποιος αλγόριθμος αποδίδει καλύτερα; Τα Decision Tree και Random Forest είναι σχεδόν ισοπαλα στο F1-weighted (0,992) και στο F1-macro ($\sim 0,91$). Το Random Forest κερδίζει οριακά στο accuracy (B: 0,9925), όμως το μεμονωμένο DT είναι καλύτερο στο F1-macro. Η εξήγηση: για αυτό το συγκεκριμένο dataset μετά το feature selection του Q1, ένα καλά ρυθμισμένο δέντρο πιάνει όλα τα patterns· το RF averaging δεν προσφέρει μεγάλη οριακή βελτίωση γιατί το πρόβλημα δεν είναι high-variance-limited. Το LR υστερεί σημαντικά (F1-macro = 0,781) επειδή οι attack classes δεν είναι γραμμικά διαχωρίσιμες στο 47-feature space.

2. Δίνει το Grid Search με CV διαφορετικά hyperparameters σε σχέση με split-based; LR: ίδια best params και στα δύο σενάρια - το single validation set των $\sim 27K$ rows είναι αρκετά μεγάλο ώστε να συμφωνήσει με τη CV. **DT:** διαφορετικά (A: max_depth= 20, B: unbounded). **RF:** διαφορετικά (A: max_depth= 20, B: unbounded). Η CV τείνει να προτιμά unbounded depth γιατί ο μέσος όρος 5 folds είναι σταθερότερος σε ελαφρές διαφορές· ένα single val set μπορεί τυχαία να «τιμωρήσει» το unbounded model αν κάποια rare-class rows πέσουν εκεί και overfittingιστούν. **Γενικό μύθημα:** όταν το dataset είναι περιορισμένο ή οι κλάσεις σπάνιες, η CV είναι πιο αξιόπιστη.


3. Ποιες attack types είναι οι πιο δύσκολες; Από τις row-normalized confusion matrices (Figs. 4.7, 4.8):

- **Web Attacks (Brute Force / XSS / SQL Injection):** συγχέονται μεταξύ τους και με BENIGN. Αναπαράγουν normal HTTP traffic με μικρές υπογραφές.
- **Infiltration (36 rows) και Heartbleed (11 rows):** λόγω περιορισμένων training data τα signatures είναι αναξιόπιστα. Συχνά κατηγοριοποιούνται ως άλλη high-frequency DoS κλάση.
- **Bot:** μπερδεύεται με BENIGN επειδή το command-and-control traffic μπορεί να μιμείται κανονικές HTTP/HTTPS calls.


Οι «εύκολες» κλάσεις είναι DDoS, DoS Hulk, PortScan, FTP-Patator, SSH-Patator - έχουν πολύ διακριτές υπογραφές (rate spikes, αποκλίνοντα packet sizes, καταιγίδες SYN χωρίς ACK).

4. Πώς επηρεάζει το class imbalance τα αποτελέσματα; Σε όλα τα μοντέλα ισχύει $F1_w \gg F1_m$. Για το LR, η διαφορά είναι $0,965 - 0,781 = 0,184$ - τεράστια. Για DT/RF μειώνεται σε $\sim 0,08$, δηλώνοντας ότι τα non-linear μοντέλα πιάνουν και τις rare classes (όχι τέλεια, αλλά πολύ καλύτερα). Η επιλογή μετρικής εξαρτάται από την εφαρμογή:

- IDS που θέλει να πιάνει κάθε attack type $\rightarrow$ F1-macro.
- Production filter που σταθμίζεται με τη συχνότητα traffic $\rightarrow$ F1-weighted.



Σχήμα 4.7: Random Forest (Σενάριο B) - row-normalized confusion matrix. Οι διαγώνιοι κοντά στο 1 δείχνουν per-class recall· οι off-diagonal entries δείχνουν confusion patterns.



Σχήμα 4.8: Logistic Regression (Σενάριο B) - row-normalized confusion matrix. Σημαντικά χειρότερη ποιότητα στις Web-Attack και Bot κλάσεις σε σχέση με το RF.

4.6 Σύνοψη Q2

Μέγεθος	Τιμή
Subsample (cap = 25K)	134.187 rows
Train / Val / Test	80.511 / 26.838 / 26.838
Αλγόριθμοι	LR, DT, RF
Σενάρια	A (split), B (CV)
LR grid combinations	16
DT grid combinations	24
RF grid combinations	18
Best model (F1-weighted)	RF B: 0,9921
Best model (F1-macro)	RF A: 0,9116
Best single-algorithm (F1-weighted, F1-macro combo)	DT / RF παρόμοια
Worst F1-macro	LR: 0,7810

Πίνακας 4.5: Βασικά αποτελέσματα του Q2.

Κεφάλαιο 5

Ερώτημα 3: Συσταδοποίηση

Στο κεφάλαιο αυτό αποκρύπτουμε τη στήλη `Label` και εφαρμόζουμε τρεις unsupervised αλγορίθμους clustering (K-Means, Agglomerative Hierarchical, DBSCAN) στο PCA-μειωμένο feature space. Στόχος: να δούμε αν η ενδογενής δομή των δεδομένων αντιστοιχεί στις γνωστές attack categories - χωρίς supervisory signal. Αξιολογούμε με Silhouette και Davies-Bouldin Index (όπως ζητά η εκφώνηση), και επιβεβαιώνουμε την αντιστοίχιση clusters $\leftrightarrow$ labels post-hoc μέσω heatmap.


5.1 Preprocessing και PCA

Χρησιμοποιούμε το ίδιο per-class subsampling με το Q2 (cap = 25.000 στο default fast mode $\rightarrow$ 134.187 rows). Όλες οι rare classes (Heartbleed, SQL Injection, Infiltration) διατηρούνται πλήρως.

Γιατί StandardScaler είναι κρίσιμο εδώ. Όλοι οι αλγόριθμοι clustering που χρησιμοποιούμε είναι distance-based: η ευκλείδεια απόσταση μεταξύ points ορίζει τα clusters. Χωρίς scaling, ένα feature σε scale 10^6 (Bytes/s) θα κυριαρχούσε 100% τη μέτρηση - ουσιαστικά το clustering θα ήταν ταξινόμηση μόνο πάνω σε αυτό το ένα feature. Το StandardScaler εξασφαλίζει ότι κάθε feature συνεισφέρει εξίσου.

PCA - dimensionality reduction. Δύο λόγοι:

- *Curse of dimensionality:* σε υψηλές διαστάσεις (47 features), όλες οι αποστάσεις τείνουν να γίνονται παρόμοιες, και η έννοια του «κοντινός γείτονας» χάνει νόημα. Το PCA συμπυκνώνει την variance σε λιγότερα orthogonal axes, αποκαθιστώντας το distance signal.
- *Ταχύτητα:* K-Means και DBSCAN κλιμακώνονται γραμμικά ως προς τη διάσταση. Από 47 $\rightarrow$ 17 components είναι $\sim 3\times$ speedup.




Σχήμα 5.1: PCA explained variance: per-component (μπλε bars) και cumulative (κόκκινη γραμμή). Με **17 components** καλύπτουμε $\sim 87\%$ της variance· επιλέγουμε αυτό ως input για όλους τους αλγορίθμους clustering. Παρατηρήστε ότι ο πρώτος component συλλαμβάνει μόνο $\sim 17\%$: δεν υπάρχει ένα κυρίαρχο axis. Η information είναι κατανεμημένη σε πολλά components.

5.2 K-Means

Διαίσθηση. Επιλογή k . Επανάληψη μέχρι σύγκλιση: (1) *Assignment* κάθε point στο πιο κοντινό centroid, (2) *Update* κάθε centroid ως μέσο όρο των points του. Συγκλίνει σε local minimum του inertia (sum of squared distances). Υποθέτει **σφαιρικά clusters παρόμοιου μεγέθους**.

Επιλογή k - Elbow + Silhouette. Σαρώνουμε $k \in [2, 15]$. Το inertia (αριστερός άξονας) μειώνεται σταθερά - δεν υπάρχει σαφής αγκώνας, αλλά το rate of decrease μειώνεται μετά το $k = 8$. Το silhouette (δεξιός άξονας) έχει local minimum στο $k = 3$ και μετά ανεβαίνει σταθερά μέχρι **maximum στο $k = 15$** (silhouette = 0,4237).




Σχήμα 5.2: K-Means - inertia (μπλε) και silhouette (κόκκινο) ανά k . Το silhouette κορυφώνεται στο $k = 15$ - ο ίδιος αριθμός με τα γνωστά labels.


Σύμπτωση. Το silhouette-best k ($= 15$) συμπίπτει με τον αριθμό των γνωστών labels ($= 15$). Δηλαδή το «reference $k = \# \text{true labels}$ » που ζητά η εκφώνηση δίνει *ίδια* αποτελέσματα με το silhouette-best k σε αυτή την περίπτωση. Αυτό από μόνο του είναι ενθαρρυντικό σήμα ότι η ενδογενής δομή των δεδομένων αντιστοιχεί στις γνωστές attack categories.

Configuration	n_clusters	Silhouette $\uparrow$	Davies-Bouldin $\downarrow$
K-Means $k = 15$ (best by silhouette / reference)	15	0,4237	0,8278

Πίνακας 5.1: K-Means - test metrics στο best k .



Σχήμα 5.3: K-Means $k = 15$ - PCA 2-D scatter. Αριστερά: colored by cluster. Δεξιά: colored by true Label. Παρατηρήστε ότι μερικές classes (DDoS, PortScan) είναι ευδιάκριτες ως compact clusters στο PCA space, ενώ η BENIGN καταλαμβάνει το πιο πολυποίκιλο γεωμετρικό χώρο.



Σχήμα 5.4: K-Means $k = 15$ - cluster composition heatmap. Row-normalized: κάθε γραμμή αθροίζει σε 1, δείχνοντας τι είναι κάθε cluster. Πολλά clusters είναι σχεδόν καθαρά μίας κλάσης ($> 90\%$), ενώ άλλα μοιράζονται μεταξύ similar attack types.


5.3 Hierarchical (Agglomerative)

Διαίσθηση. Bottom-up: ξεκινάμε με κάθε point ως ένα cluster· σε κάθε βήμα ενώνουμε τα δύο πιο κοντινά. Παράγει ένα *dendrogram*. Κόβουμε το dendrogram σε κατάλληλο height για να πάρουμε k clusters.

Linkage methods ορίζουν την «απόσταση μεταξύ clusters»:

- **single:** minimum point-to-point distance (chaining effect).
- **complete:** maximum point-to-point distance (συμπαγή σφαιρικά clusters).
- **average:** μέσος όρος όλων των ζευγών (συμβιβασμός).
- **ward:** minimum-variance criterion - ενώνει clusters που ελαχιστοποιούν την αύξηση της within-cluster variance.

Computational constraint. Η AgglomerativeClustering απαιτεί ολόκληρο τον $O(n^2)$ πίνακα αποστάσεων: για 134K rows χρειάζονται ~ 72 GB RAM - απαγορευτικό. Παίρνουμε stratified subsample 2.468 rows (~ 70 MB distance matrix) - αρκετό για διαβάσιμο dendrogram και σταθερό linkage comparison.




Σχήμα 5.5: Dendrogram (ward linkage, top 30 merges). Φαίνεται καθαρά διπλή ιεραρχική δομή: ένα μεγάλο σύνολο merges σε χαμηλό height (πορτοκαλί - κανονικό traffic και κοντινά attacks) και ένα απομονωμένο cluster (πράσινο - probably attack patterns που διαφέρουν δραματικά). Η μεγάλη κάθετη γραμμή στο height ~ 800 δείχνει την τελική συγχώνευση των δύο sub-trees.

Linkage comparison με $k = 15$ (= silhouette-best K-Means k , για consistency):


Linkage	Silhouette $\uparrow$	Davies-Bouldin $\downarrow$
ward	0,5014	0,5944
complete	0,6251	0,2924
average	0,7334	0,2185

Πίνακας 5.2: Hierarchical Clustering - σύγκριση linkage methods ($k = 15$, 2.468-row stratified subsample). Best by both metrics: average linkage.

Παρατήρηση: γιατί κερδίζει το average linkage. Συνήθως το ward είναι το πιο «καλό default». Στο δικό μας dataset υπερισχύει το average επειδή υπάρχουν λίγα μεγάλα και πολλά μικρά (rare-attack) clusters με ασύμμετρες αποστάσεις - το average linkage, που λαμβάνει υπόψη όλα τα ζεύγη points, χειρίζεται καλύτερα αυτή την ασυμμετρία από το variance-based ward.



Σχήμα 5.6: Hierarchical (average linkage, $k = 15$) - PCA 2-D scatter στο 2.468-row subsample.




Σχήμα 5.7: Hierarchical (average linkage, $k = 15$) - cluster composition heatmap.

5.4 DBSCAN

Διαίσθηση. Density-based clustering. Δεν χρειάζεται k . Έννοιες: *core point* ($\geq \text{min_samples}$ γείτονες μέσα σε ε -ακτίνα), *border point*, *noise* (label = -1). Δύο core points εντός ε ανήκουν στο ίδιο cluster.

Πλεονεκτήματα. Ανακαλύπτει clusters *αυθαίρετου σχήματος* (όχι μόνο σφαιρικά)· ανθεκτικό σε outliers (τα ταξινομεί ως noise). **Μειονεκτήματα.** Ευαίσθητο σε ε και min_samples · δυσκολεύεται με clusters διαφορετικής πυκνότητας (μία ε δεν ταιριάζει σε όλα).

Επιλογή ε - k-distance graph. Για κάθε point, απόσταση προς τον $k = 4$ πιο κοντινό γείτονα, sorted ascending. Ο «αγκώνας» της καμπύλης δείχνει ένα καλό ε - κάτω από τον αγκώνα είναι dense regions.



Σχήμα 5.8: k-distance graph ($k = 4$) πάνω σε στρωμένο sample 20.000 rows. Η κύρια καμπύλη παραμένει σχεδόν επίπεδη μέχρι το $\sim 80\%$ percentile και έπειτα εκτοξεύεται απότομα: σαφής αγκώνας στο $\varepsilon \approx 0,3-0,5$, κάτι που επιβεβαιώνει το sweep μας.

Sweep $\varepsilon \times \text{min_samples}$. $5 \times 3 = 15$ combinations σύμφωνα με την εκφώνηση:

ε	min_samples	n_clusters	n_noise	Sil. $\uparrow$	DB $\downarrow$
0,3	5	583	6.494	0,3862	0,6359
0,3	10	367	9.052	0,4265	0,6406
0,3	20	231	12.573	0,4480	0,6354
0,5	5	402	4.018	0,3620	0,7432
0,5	10	258	5.692	0,3922	0,7290
0,5	20	172	7.836	0,4321	0,7479
0,8	5	295	2.473	0,0892	0,6930
0,8	10	191	3.545	0,1007	0,7386
0,8	20	122	5.183	0,2819	0,7062
1,0	5	184	1.868	0,2156	0,5536
1,0	10	123	2.624	0,2237	0,5643
1,0	20	88	3.696	0,2584	0,6136
1,5	5	142	1.006	0,1069	0,5095
1,5	10	89	1.512	0,1021	0,4745
1,5	20	55	2.178	0,1831	0,4513


Πίνακας 5.3: DBSCAN sweep - όλες οι 15 παραλλαγές. Best silhouette: $\varepsilon = 0,3$, min_samples = 20. Best Davies-Bouldin: $\varepsilon = 1,5$, min_samples = 20. Διαφορετικές μετρικές δίνουν διαφορετικό best - κλασικό clustering trade-off.

Παρατηρήσεις.

- **Πάρα πολλά clusters** σε όλες τις configurations (55-583), πολύ περισσότερα από τα 15 πραγματικά labels. Αυτό σημαίνει ότι η ενδογενής δομή έχει πολλές sub-populations - διαφορετικά flavors του ίδιου attack type ή του BENIGN.
- **Trade-off noise vs cluster purity:** μικρό $\varepsilon \Rightarrow$ πολύ noise (12K rows με $\varepsilon = 0,3$) αλλά καλύτερο

silhouette. Μεγάλο $\varepsilon \Rightarrow$ λίγο noise αλλά θολά clusters.

- Επιλέγουμε ως best το $\varepsilon = 0,3$, $\text{min_samples} = 20$ (highest silhouette, μεσαίο noise level).



Σχήμα 5.9: DBSCAN ($\varepsilon = 0,3$, $\text{min_samples} = 20$) - PCA 2-D scatter. Τα grey x-markers είναι *noise points* (12.573 rows, $\sim 9,4\%$ του dataset).

5.5 Συγκριτική Ανάλυση

Algorithm	Config	n_clust	n_noise	Sil. $\uparrow$	DB $\downarrow$
K-Means	$k = 15$ (best/reference)	15	0	0,4237	0,8278
Hierarchical	ward, $k = 15$	15	0	0,5014	0,5944
Hierarchical	complete, $k = 15$	15	0	0,6251	0,2924
Hierarchical	average , $k = 15$	15	0	0,7334	0,2185
DBSCAN	$\varepsilon = 0,3$, $ms = 20$	231	12.573	0,4480	0,6354
DBSCAN	$\varepsilon = 1,5$, $ms = 20$	55	2.178	0,1831	0,4513

Πίνακας 5.4: Q3 - σύγκριση best configurations ανά αλγόριθμο. *Caveat*: το Hierarchical εκπαιδεύτηκε σε 2.468-row subsample λόγω $O(n^2)$ memory.

5.5.1 Απαντήσεις στις Ερωτήσεις της Εκφώνησης

1. Αντιστοιχούν τα clusters σε meaningful attack categories; Μερικώς, ναι. Από τα cluster-to-Label heatmaps βλέπουμε ότι αρκετά clusters είναι σχεδόν καθαρά μίας κλάσης - ιδίως οι χαρακτηριστικές attack υπογραφές (DDoS, DoS Hulk, PortScan, FTP/SSH-Patator). Όμως:

- Η BENIGN διασκορπίζεται σε πολλά clusters - δεν είναι ομοιογενής class αλλά μείγμα από web/email/SSH/bulk traffic με διαφορετικές υπογραφές. Είναι λογικό: «κανονικό» traffic έχει πολλές νόμιμες μορφές.
- Οι rare attacks (Heartbleed, SQL Injection, Infiltration) σπάνια έχουν δικό τους cluster· τυπικά απορροφώνται μέσα σε BENIGN clusters ή σε άλλες DoS-like ομάδες.
- Επιβεβαίωση: το silhouette-best k για το K-Means είναι ακριβώς 15, ίδιο με τα true labels. Αυτό από μόνο του είναι ισχυρό σήμα ότι η ενδογενής γεωμετρία αντιστοιχεί στις attack categories.

2. Ποιος αλγόριθμος συλλαμβάνει καλύτερα την true structure; Hierarchical με average linkage (silhouette = 0,733, DB = 0,219) έχει καθαρά τα καλύτερα νούμερα. Ωστόσο τρέχει σε δραματικά μικρότερο sample (2,5K rows έναντι 134K), και άρα τα metrics δεν είναι 1:1 συγκρίσιμα. Σε ίσο sample:

- **K-Means** $k = 15$: silhouette $\sim 0,42$ - σταθερό baseline.
- **DBSCAN best**: silhouette $\sim 0,45$ - οριακά καλύτερο, αλλά εις βάρος του να αφήνει 12.5K rows ως noise.

Με μετρικές που δίνουν ισότιμη σημασία και στο coverage (πόσα rows καταλήγουν σε valid cluster) και στην ποιότητα των clusters, **το K-Means είναι το πιο πρακτικό** σε αυτό το dataset: σαφές ranking στο silhouette, καμία row ως noise, σταθερά μετρικά.

3. Τι ανακαλύπτουμε χωρίς labels που δεν φαίνεται με supervised; Τρεις τύποι insight που το Q2 (supervised) δεν παράγει:

- **Sub-clusters μέσα σε γνωστά labels.** Π.χ. το BENIGN χωρίζεται σε > 5 clusters - διαφορετικοί τύποι κανονικού traffic. Αυτό σημαίνει ότι στο supervised setting, ο classifier «μαθαίνει» το BENIGN ως μία class αλλά πρακτικά πρέπει να μάθει πολλά distinct flavors.
- **Outliers / unknown attacks.** Το DBSCAN σημείωσε 12.573 rows ως noise - μερικά μπορεί να είναι zero-day attacks ή corrupted flows που δεν ταιριάζουν σε γνωστή κατηγορία.
- **Γεωμετρική επιβεβαίωση των features.** Το silhouette-best k ισούται με τον αριθμό των true labels (15). Αυτό είναι «δωρεάν» επιβεβαίωση ότι τα 47 selected features περιέχουν αρκετή information για να διακρίνουν τις attack categories - χωρίς ποτέ να είδαμε labels.

5.6 Σύνοψη Q3

Μέγεθος	Τιμή
Subsample (cap = 25K)	134.187 rows
PCA components ($\geq 85\%$ variance)	17
Hierarchical subsample	2.468 rows
K-Means k-search	$k \in [2, 15]$
K-Means best k (silhouette)	15
K-Means metrics	sil 0,4237 / DB 0,8278
Hierarchical best linkage	average
Hierarchical metrics	sil 0,7334 / DB 0,2185
DBSCAN sweep	$5 \times 3 = 15$ combos
DBSCAN best (silhouette)	$\varepsilon = 0,3, ms = 20$
DBSCAN best metrics	sil 0,4480 / DB 0,6354
DBSCAN noise points (best)	12.573 ($\sim 9,4\%$)

Πίνακας 5.5: Βασικά αποτελέσματα του Q3.

Κεφάλαιο 6

Συμπεράσματα

6.1 Σύνοψη Όλου του Αγωγού

Το παρόν project υλοποίησε end-to-end ML αγωγό πάνω στο CIC-IDS-2017: EDA + cleaning (Q1), supervised classification (Q2) και unsupervised clustering (Q3). Όλη η αναπαραγωγή στηρίζεται σε ένα κοινό cached Parquet snapshot (`data/cic_ids_2017_clean.parquet`, 221,9 MB) και μία ενιαία `RANDOM_STATE = 42`.

6.2 Συμπεράσματα ανά Ερώτημα

6.2.1 Q1 - Δομή και Καθαρισμός των Δεδομένων

1. Το **CIC-IDS-2017 απαιτεί προσεκτικό καθαρισμό** πριν οποιοδήποτε μοντέλο: 4.376 Infs, 255.236 exact duplicates και corrupted bytes στις ετικέτες των Web Attacks.
2. Η **ανισορροπία είναι ακραία** ($\sim 195\,000 : 1$). Αυτό διαμόρφωσε κάθε επιλογή στο Q2 (class_weight, macro-F1, stratified splitting) και στο Q3 (per-class subsampling cap).
3. Το **feature space είναι υπερ-παραμετροποιημένο**. Οι 78 αρχικές αριθμητικές στήλες έκρυβαν 22 near-duplicates και 8 constants. Μετά την αφαίρεση μένουν **47 features** με γνήσια διακριτική πληροφορία.
4. Η χρήση **Parquet** για το cached snapshot μειώνει το I/O cost από ~ 60 sec (raw CSV parsing) σε < 2 sec.

6.2.2 Q2 - Supervised Classification

1. **Decision Tree και Random Forest είναι σχεδόν ισόπαλα** στο top-level. RF B κερδίζει οριακά στο F1-weighted (0,9921). RF A κερδίζει στο F1-macro (0,9116). Το LR υστερεί σημαντικά στο macro (0,781) επειδή οι attack classes δεν είναι γραμμικά διαχωρίσιμες στο 47-feature space - οι rare attacks χρειάζονται non-linear decision boundaries.
2. Το **split-vs-CV protocol δίνει ίδια best params για το LR** (μεγάλο val set αρκεί), αλλά διαφορετικά για DT και RF (CV προτιμά unbounded max_depth). Σε γενικές γραμμές, η CV είναι πιο αξιόπιστη όταν τα data είναι περιορισμένα ή υπάρχουν rare classes.
3. Η **Destination Port είναι το μόνο feature που dominate ένα μεμονωμένο DT** (importance $\sim 0,39$). Στο RF η importance εξομαλύνεται μέσω bagging - top-5 features έχουν importance 0,04-0,07. Αυτή η εξισορρόπηση είναι το χαρακτηριστικό signature του ensemble averaging.
4. Configurable mode (SUBSAMPLE_CAP): **25_000** (fast, ~ 134 K rows, ~ 15 min) / **100_000** (medium, ~ 500 K rows, ~ 2 -4 hours) / **None** (full $\sim 2,5$ M rows, ~ 12 + hours). Το LR με solver **saga** είναι ο κύριος bottleneck σε full mode.

6.2.3 Q3 - Unsupervised Clustering

1. **17 PCA components** καλύπτουν $\sim 87\%$ της variance. Δεν υπάρχει ένα κυρίαρχο axis - η information είναι κατανεμημένη.
2. **To silhouette-best k για το K-Means είναι ακριβώς 15** - ίσο με τον αριθμό των γνωστών labels. Αυτή η σύμπτωση είναι ισχυρό σήμα ότι η ενδογενής γεωμετρία των δεδομένων αντιστοιχεί στις attack categories (γεωμετρική επιβεβαίωση του feature engineering του Q1).
3. **Hierarchical με average linkage** έδωσε τα καλύτερα metric numbers (silhouette 0,733, DB 0,219), αν και εκπαιδεύτηκε σε 2.468-row stratified subsample λόγω του $O(n^2)$ memory cost (η πλήρης distance matrix για 134K rows είναι ~ 72 GB).
4. **DBSCAN ταξινομεί $\sim 9,4\%$ του dataset ως noise** (best config: $\varepsilon = 0,3$, `min_samples = 20`). Αυτά τα noise points είναι candidate outliers / unknown attacks - πληροφορία που το supervised setting του Q2 δεν παράγει.
5. **H BENIGN class διασπείρεται σε πολλά clusters**, ενώ χαρακτηριστικές attack υπογραφές (DDoS, PortScan, FTP-Patator) σχηματίζουν compact και σχεδόν καθαρά clusters. Δηλαδή το κανονικό traffic είναι μείγμα από web/email/SSH/bulk flavors, ενώ οι attacks έχουν διακριτές statistical signatures.

6.3 Συνολικά Διδάγματα και Best Practices

- **Pipeline-driven preprocessing.** Σε όλο το Q2 και Q3, κάθε scaling και dimensionality reduction βρίσκεται μέσα σε Pipeline ή εφαρμόζεται μόνο στο training fold ώστε να αποφευχθεί data leakage.
- **Reproducibility.** `utils.RANDOM_STATE = 42` χρησιμοποιείται σε κάθε split, model seed, και stochastic operation (sampling, K-Means init, RF bootstrap, GridSearchCV folds, PCA solver). Re-execution οποιουδήποτε notebook top-to-bottom δίνει bit-identical αποτελέσματα.
- **Caching.** Το Q1 παράγει το 221,9 MB Parquet snapshot που και τα Q2 και Q3 φορτώνουν σε < 2 sec - όχι re-execution του πλήρους Q1 αγωγού σε κάθε run.
- **Configurable compute mode.** Q2 και Q3 εκθέτουν `SUBSAMPLE_CAP` ώστε ο χρήστης να επιλέγει trade-off speed-vs-fidelity χωρίς αλλαγές σε άλλο μέρος του κώδικα.
- **Διαχωρισμός responsibilities.** Reusable helpers ζουν στο `utils.helpers` (15 functions, re-exported μέσω `utils/__init__.py`). Notebooks είναι αμιγώς διδακτικά - Greek Γιατί cells με τεκμηρίωση κάθε απόφασης.

6.4 Πιθανές Επεκτάσεις

- **Σύγχρονοι classifiers:** XGBoost, LightGBM ή gradient boosting θα μπορούσαν να βελτιώσουν περαιτέρω τα macro-F1 metrics (RF μας δίνει 0,912).
- **Threshold tuning:** για production IDS, η εξάρτηση από F1-macro vs precision/recall ζευγάρια ανά class θα οδηγούσε σε διαφορετική τοποθέτηση thresholds.
- **Σύγχρονα clustering:** HDBSCAN (αυτόματη επιλογή ε , χειρίζεται variable density) ή UMAP-based clustering θα μπορούσαν να βελτιώσουν τη DBSCAN υλοποίηση.
- **Online / streaming setup:** το CIC-IDS-2017 είναι static· σε production setting, η ανίχνευση πρέπει να γίνεται σε real-time πάνω σε streaming flows.

Παράρτημα Α΄

Οδηγίες Εγκατάστασης και Εκτέλεσης

Α΄.1 Απαιτήσεις

- Python 3.10+ (δοκιμάστηκε σε 3.12).
- ~ 16 GB RAM (το full load απαιτεί ~ 4-6 GB μετά το `_optimize_memory`).
- ~ 3 GB ελεύθερου χώρου (raw CSV + Parquet cache).

Α΄.2 Εγκατάσταση

```
Εγκατάσταση
1 # clone και venv
2 git clone https://github.com/IBilba/network-intrusion-detection-ml.git
3 cd network-intrusion-detection-ml
4 python -m venv .venv
5 source .venv/bin/activate # ή .venv\Scripts\activate στα Windows
6
7 # dependencies
8 pip install -r requirements.txt
9
10 # data τοποθέτηση( των 8 CSV στο data/)
11 # από Kaggle: https://www.kaggle.com/datasets/cicdataset/cicids2017
```

Α΄.3 Εκτέλεση του Q1


```
Run
1 # Εκτέλεση end-to-end γράφει( figures, CSV, Parquet)
2 jupyter nbconvert --to notebook --execute notebooks/q1_eda.ipynb \
3 --output q1_eda.ipynb
```

Μετά την εκτέλεση, τα παραγόμενα αρχεία βρίσκονται σε:

- `outputs/figures/`: 5 PNGs (label distribution, histograms, boxplots, heatmap).
- `outputs/results/`: 7 CSVs (column catalogue, describe, label distribution, correlation με label, top correlated pairs, removed features, final feature list).
- `data/cic_ids_2017_clean.parquet`: το cached clean dataset για τα Q2/Q3.

Α'4 Εκτέλεση των Q2 και Q3

Τα Q2 και Q3 διαβάζουν μόνο το cached Parquet snapshot - δεν ξανατρέχουν το pipeline του Q1. Πριν την εκτέλεση, ανοίξτε το αντίστοιχο notebook και προσαρμόστε τη μεταβλητή `SUBSAMPLE_CAP` στο preferred mode (25_000 = fast, 100_000 = medium, None = full).



```
Run
1 # Q2: classification - LR / DT / RF, σενάρια A και B
2 jupyter nbconvert --to notebook --inplace --execute \
3   notebooks/q2_classification.ipynb \
4   --ExecutePreprocessor.timeout=7200 \
5   --ExecutePreprocessor.kernel_name=nids
6
7 # Q3: clustering - PCA + K-Means + Hierarchical + DBSCAN
8 jupyter nbconvert --to notebook --inplace --execute \
9   notebooks/q3_clustering.ipynb \
10  --ExecutePreprocessor.timeout=7200 \
11  --ExecutePreprocessor.kernel_name=nids
```

Παραγόμενα αρχεία:

- **Q2:** 13 PNGs (6 confusion matrices, 2 feature-importance bars, 1 F1 comparison, 1 LR coefficient heatmap, 2 DT visualizations, 1 RF single-tree) + 12 CSVs (subsample, split, label encoding, 6 grid CSVs, 2 feature-importance, comparison table, label encoding).
- **Q3:** 11 PNGs (PCA variance, K-Means elbow/silhouette, 2 K-Means scatters, K-Means heatmap, dendrogram, hier scatter + heatmap, k-distance, DBSCAN scatter + heatmap) + 8 CSVs (PCA variance, k-search, linkage comparison, DBSCAN sweep, comparison, 3 heatmap composition tables).

Α'5 Αναπαραγωγιμότητα

Όλες οι στοχαστικές λειτουργίες (sampling, shuffling, CV folds) θα χρησιμοποιούν τον ίδιο `RANDOM_STATE = 42` από το `utils/helpers.py`. Με τον ίδιο seed και το ίδιο σύνολο δεδομένων, όλοι οι αριθμοί του Πίνακα 3.6 είναι bit-exactly αναπαραγώγιμοι.